

# Curricular Contrastive Regularization for Physics-aware Single Image Dehazing

## 摘要

考虑到图像的不适定性质，引入负图像的信息作为下界，对单幅图像的去雾进行了对比正则化。然而，对比样本是不一致的，因为负样本通常与清晰的（即，积极的）图像相距较远，使得解决方案空间仍然受到限制。此外，深度去雾模型的可解释性对雾霾过程的物理特性探索不足。这里提出了一种创新的单图像去雾技术，名为 C2PNet，它采用了 Curricular Contrastive 正则化方法。与传统的对比正则化不同，该方法利用共识对比空间，通过结合雾化图像和其他方法的恢复作品中的负样本，增强了下界约束。该技术针对不同负样本间的学习难度不平衡问题，应用了一种课程学习策略。C2PNet 还引入了一个基于大气散射模型的物理感知双分支单元，从而提高了特征空间的可解释性。在 SOTS-室内和 SOTS-室外数据集上的广泛测试显示，C2PNet 在 PSNR 上分别实现了 3.94dB 和 1.50dB 的显著提升，显著优于现有方法。

**关键词：**C2PNET; Curricular Contrastive

## 1 引言

雾霾作为一种常见的大气现象，明显降低了拍摄图像的质量，严重限制了后续的高级视觉任务的执行，如车辆重新识别 [2] 和场景理解 [13]。与其他图像恢复任务求解器的出现类似 [5, 6, 14]。

处理基于视觉的应用程序需要有效的图像去雾技术。深度学习单张图像去雾方法可大致分为两类：物理自由法和物理感知法。对于前者来说，大多数使用真实图像（没有雾的图像，即 ground-truth images）与去雾后的预测图像之间的 L1/L2 距离来保证一致性。这意味着模型会尝试最小化真实图像与预测图像之间的像素级差异。但都忽略了负样本的问题，所以提出了对比正则化（CR）。CR 方法引入不同的雾图像作为负样本，而真实清晰图像作为正样本，并使用对比学习确保解空间是封闭的。然而，存在一个问题是负样本的内容与正样本可能完全不同，它们在特征空间中的嵌入可能过于疏远，导致解空间依然过于宽松（under-constricted），即模型可能无法充分利用负样本信息来约束学习过程，找到更加准确的去雾解。

为了解决负样本与正样本相差太远的问题，一种直观的方法是在共识对比空间内使用负样本来提供更好的下限约束。如图 1 下面板所示。

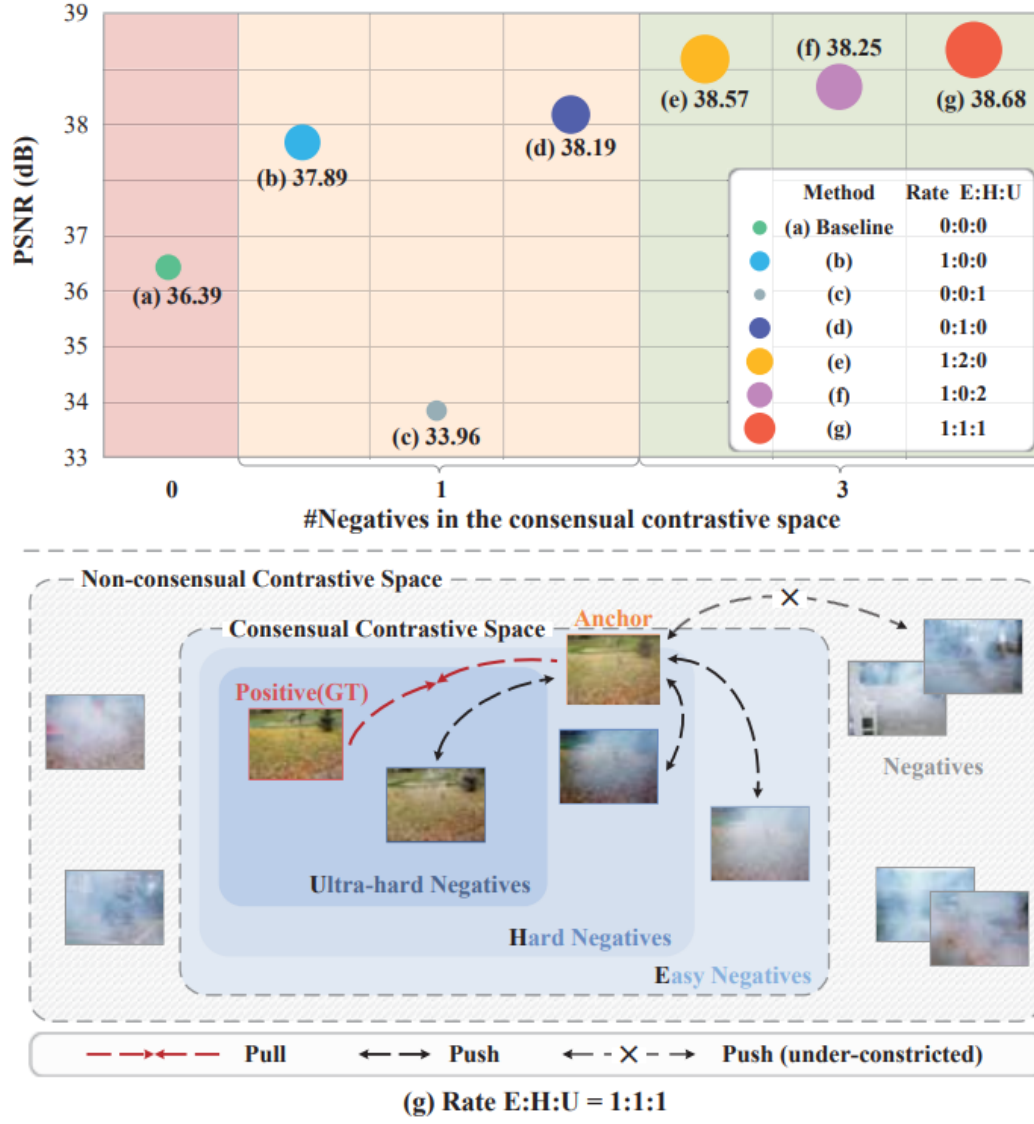


图 1. 上图: 基于共识性对比空间中否定的三个难度等级的对比正规化检查。下面板: 在同意和非同意空间中对对比样本的说明。

这些负样本可以由模糊的输入图像和其他现有方法的恢复结果（即之前尝试去雾但可能还残留一些雾的图像）组成。在这种情况下，负样本因为与雾相关的多样性而与正样本更“接近”，而不是由于其他的语义差异。然而，如果一个负样本在嵌入空间中与正样本过于接近，就会出现一个固有的困境：负样本的推力可能会抵消正样本的拉力。在训练的早期阶段，这种学习困难可能会使预测的结果（即 anchor，锚点）难以朝向正样本移动，因为模型难以区分向哪个方向学习。

这种直觉在如图 1 所示：的上面板中得到了进一步的检验。我们以 FFA-Net 为基线（行 (a)），以 SOTS-indoor 为测试数据集，探讨不同难度的共识空间中消极因素的影响。具体来说，我们将负片的难度定义为容易 (E)、困难 (H) 和超困难 (U) 三个级别，采用朦胧输入作为容易负片，并采用粗策略区分后两种类型，即负样本的 PSNR 是否大于 30。首先，在单负数的情况下（行 (b)-(d)），一个有趣的发现是，与其他两种设置相比，使用一个作为负数的硬样本获得了最好的性能，而使用一个超硬负数甚至比基线更差。这表明，一个“封闭”的负值

有可能提高去雾模型的有效性，但并不是越封闭越好，因为学习困难。而在 (e)-(g) 行多负片的情况下，我们发现全面覆盖不同难度的负片，包括超硬样本，可以获得最好的效果。这意味着不同难度水平的消极因素都对训练阶段有影响。这些观察促使我们去探索在训练过程中，如何明智地在一个一致同意的空间内将多个负对安排到 CR 中。

进入物理感知的深度模型领域，大多数模型在原始空间中利用大气散射模型 [31,32]，而没有充分探索有益的特征级信息。PFDN[11] 是唯一一个试图将物理模型表示为网络中的基本单元的作品。该单元被设计成一个共享的结构，以预测对应于大气光和透射图的潜在特征。然而，前者通常被认为是齐次的，而后者是非齐次的，因此它们的特征不能以相同的方式近似。因此，如何利用物理模型准确实现深度网络特征空间的解释性仍然是一个开放的问题，这是我们感兴趣的另一个方面。

在这篇论文中，提出了一种课程对比正则化，使用朦胧或恢复的图像作为消极的共识空间图像去雾，以解决第一个问题。基于我们的分析，我们提出了一种课程学习策略来安排这些消极信息以减少学习歧义，这表明共识性消极信息的难度会影响正则化的有效性。具体来说，我们将否定分为简单、困难和超困难三种类型，并在 CR 中对对应的否定对赋予不同的权重，同时在训练过程中，随着锚点在表征空间中向正方向移动，对否定对的难度水平进行动态调整。这样，所提出的正则化方法可以使去雾模型在更紧凑的解空间内稳定优化。

本文提出了 C2PNet 网络，通过课程对比正则化优化去雾效果，显著提升了在特定数据集上的 PSNR。采用了自适应课程学习策略，动态调整负样本的难度，减轻学习模糊度。通过设计物理意识双分支单元 (PDU)，推动特征传输和提取，从而更精确地合成清晰图像特征。

1) 2PNet 是一个新颖的去雾网络，它结合了课程对比正则化和基于物理先验的特征空间。提供了在合成数据和真实世界场景下优于当前最先进技术去雾效果，并在 SOTS-indoor 和 SOTS-outdoor 数据集上分别实现了 3.94dB 和 1.50dB 的显著 PSNR 提升。

2) 提出的正则化方法采用了基于共识负样本的去雾策略，并整合了一个自包含的课程学习策略，这个策略动态调整负样本的优先级和难度水平。它也被证明可以作为一个通用的正则化技术，增强了现有最先进技术的性能，超越了以往的相关方法。

3) 基于一个前所未有的物理模型的表达式来构建 PDU。这种创新的设计在物理先验的指导下，促进了特征空间的传递和提取。

## 2 相关工作

传统的单图像去雾方法主要基于大气散射模型 [12]。他们专注于设计手工制作的先验，如 [8] 之前的暗通道和 [15] 之前的颜色衰减。然而，这些先验可能不足以在实践中描述复杂的场景。基于早期学习的方法 [1, 12] 利用深度神经网络预测物理模型中的透射图和大气光，获得潜在的清晰图像。然而，估计的不准确性可能会累积，阻碍了对无雾图像的可靠推断。随

着大霾数据集 [9] 的出现，数据驱动方法 [3, 7, 10] 得到了迅速发展。FFANet [11] 引入了特征关注 (FA) 块，利用通道和像素关注来改善雾霾去除。DeHamer [7] 结合 CNN 和 Transformer 进行图像去雾，可以在 Transformer 中聚集长期关注，在 CNN feature 中聚集局部关注。注意，这些方法不考虑欺辱过程的物理性质。进一步，Dong 等人提出了一种基于物理模型推导的特征去雾单元 (feature dehazing unit, FDU) [4]。据我们所知，这项工作是唯一一个在特征空间考虑物理模型的工作，避免了在原始空间中发生的累积误差。然而，FDU 使用共享结构来预测这些未知因素，而不考虑其不同的物理特性。为了解决这一问题，我们重新理解了图像去雾的物理模型，并构造了一种新的物理感知双分支单元来实现图像去雾。

### 3 本文方法

#### 3.1 本文方法概述

我们的目标有两个:1) 目标是增强雾霾去除中特征空间的可解释性，2) 试图通过使用对比样本来定义一个更简洁的解决方案空间。图 2描述了 C2PNet 的复杂架构。为了实现最初的目标，受大气散射模型的启发，开发了一个物理知识丰富的双分支装置。对于第二个目标，设计了一种独特的对比正则化方法，结合了共识否定和自给自足的课程学习策略来解决学习挑战。重要的是，基于课程的对比正则化被设计成与网络无关，允许其在各种除雾网络中应用。

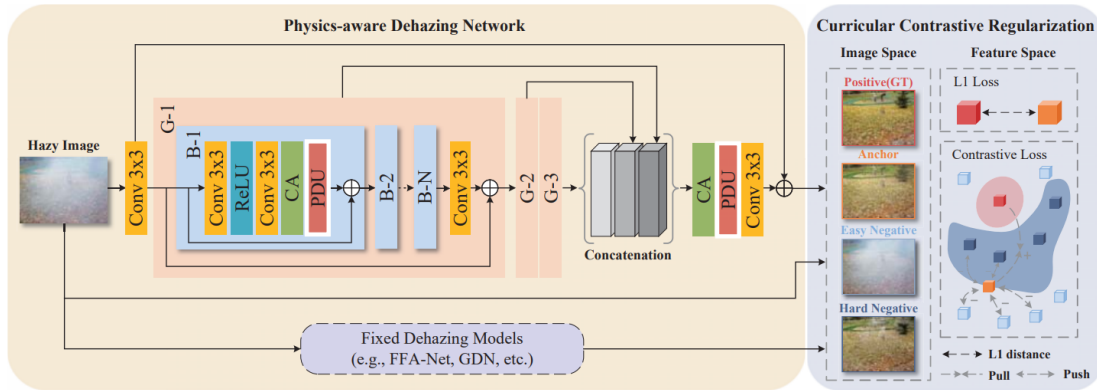


图 2. C2PNet 单图像去雾的说明

#### 3.2 物理感知双分支单元

大气散射模型用于描述雾霾图像  $I$  的形成，可用公式  $I(x) = T(x)J(x) + (1-T(x))A$  表达，其中  $J$  是清晰图像， $T$  是传输图， $A$  代表大气光， $x$  是像素索引位置。 $T$  和  $A$  未知使得去霾问题非常棘手。相比直接估计这两个未知量的传统方法，我们引入特征空间中的物理先验来增强模型的可解释性。根据 FDU 的思想，提出了物理感知双分支单元 (PDU)，该单元基于特征空间的物理模型设计。如图 3所示。



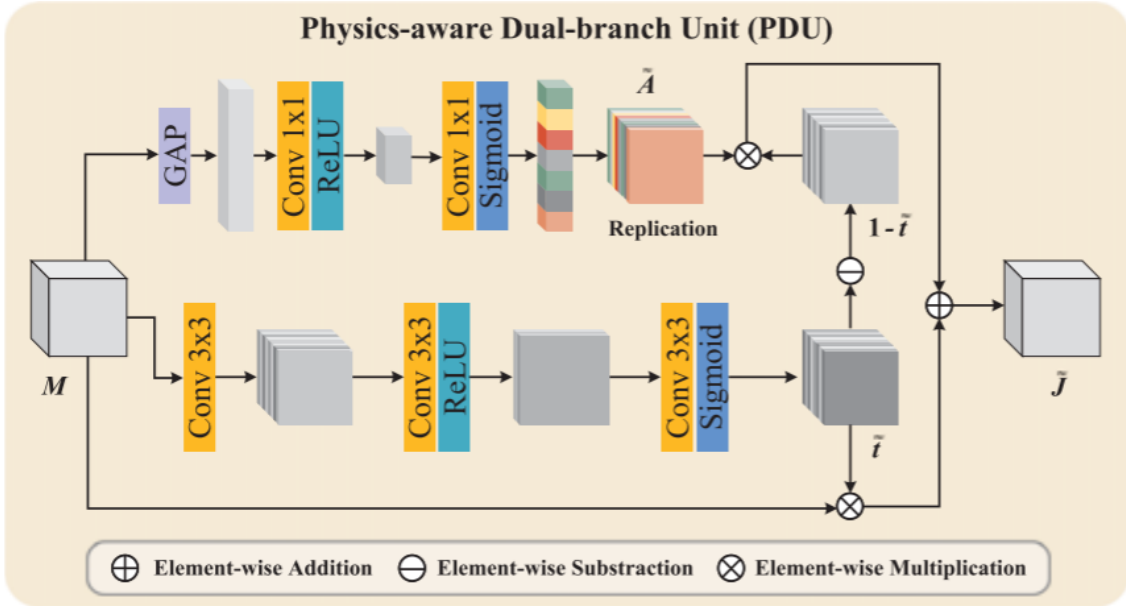


图 3. 提出的 PDU 的结构

首先对清晰图像  $J$  的表示进行重新定义, 得到  $J(x) = \frac{I(x)}{T(x)} + A \left(1 - \frac{1}{T(x)}\right)$ , 利用卷积核  $k$ , 可以对这个方程进行特征提取, 得到改写的公式  $k \otimes J = k \otimes \left(I \odot \frac{1}{T}\right) + k \otimes A - k \otimes \left(A \odot \frac{1}{T}\right)$ 。其中  $\otimes$  表示卷积算子,  $\odot$  表示哈达玛积。随后, 采用矩阵向量形式  $K, J, I, A, 1/T$ , 并将上述方程重写为  $KJ = KDI + KA - KDA$ , 其中  $D$  是对应于  $1/T$  的对角矩阵。

此外, 将  $KD$  矩阵分解为两个矩阵  $Q$  和  $K$  的乘积。定义  $\tilde{A}$  为  $KA$  的近似, 表示大气光特征,  $\tilde{t}$  为  $Q$  的近似, 与传输图相关联。基于这些定义, 我们可以从方程  $KJ = Q(KI) + KA - Q(KA)$  出发, 假设  $\tilde{t}$  的通道数与输入特征  $M$  的通道数相匹配, 从而计算物理感知特征  $\tilde{J}$  为  $\tilde{J} = M \odot \tilde{t} + \tilde{A} - \tilde{A} \odot \tilde{t}$ 。

PDU 的上分支的设计是为了生成  $\tilde{A}$ , 它代表大气光的特性。在这一过程中, 我们通常会假定大气光的分布是均匀的。基于这样的假设, 全局平均池化 (Global Average Pooling, 简称 GAP) 被用来简化特征空间, 移除那些不必要的信息。具体地, 大气光的特征  $\tilde{A}$  的计算可以通过以下公式得到:

$$\tilde{A} = H(\sigma(\text{Conv}^N(\text{Rel.U}(\text{Conv}^{\frac{N}{N}}(\text{GAP}(M))))))$$

这个公式展现了将原始特征通过卷积层和激活函数处理, 再经过全局平均池化得到精简特征后, 如何估计大气光特征的过程。

与此同时, PDU 的下分支负责生成与传输图  $\tilde{t}$  相关的特征。这一分支中运用了一系列的卷积层来逼近  $\tilde{t}$ , 即:

$$\tilde{t} = \sigma(\text{Conv}^N(\text{Rel.U}(\text{Conv}^{\frac{N}{N}}(\text{Conv}^N(M))))))$$

在这里,  $\text{Conv}^N$  表示卷积操作,  $\sigma$  是激活函数, 而  $\text{Rel.U}$  代表相对不确定性的函数。通过这样的序列操作, 我们可以从原始图像特征中提取出与雾霾去除密切相关的传输图特征。

利用上述定义, PDU 能够根据物理模型产生解释性特征  $\tilde{J}$ , 这些特征对于后续的图像恢复过程至关重要。不同于 FDU, PDU 在设计时特别考虑到了  $T$  和  $A$  的物理属性。这一双分

支的设计使得 PDU 不仅能估计特征，而且能以一种互动的方式捕捉到更多有用的信息，这对于恢复清晰的图像来说是必不可少的。

### 3.3 课程对比正规化

对于图像去雾的正则化，锚为去雾网络恢复的结果，正数为 ground truth，负数包括一个雾蒙蒙的输入和多个与正数不一致的雾蒙蒙的图像。这个正则化  $R$  的目标是最小化嵌入锚点和正锚点之间的 L1 距离，同时最大化它们与负锚点之间的距离，由

$$R = \sum_{i=1}^n \xi_i \frac{\|V_i(J) - V_i(f(I, \theta))\|_1}{\sum_{q=1}^r \|V_i(U_q) - V_i(f(I, \theta))\|_1 + E_i}, \quad (1)$$

其中  $E_i = \|V_i(I) - V_i(f(I, \theta))\|_1$ ,  $f(\cdot, \theta)$  表示参数为  $\theta$  的去雾网络,  $V_i(\cdot)$ ,  $i = 1, 2, \dots, n$  从预训练的 VGG-19 [37] 中提取第  $i$  个隐藏特征, 非共识负样本的数量  $\{U_j\}$  是  $r$ , 而  $\{\xi_i\}$  是超参数的集合。如图 4 所示, 引入的锚点与非共识负样本之间的对比不能提供一个满意的解空间下界。非共识负样本通常与正样本相距较远, 导致一个限制修复质量的解空间不受约束。

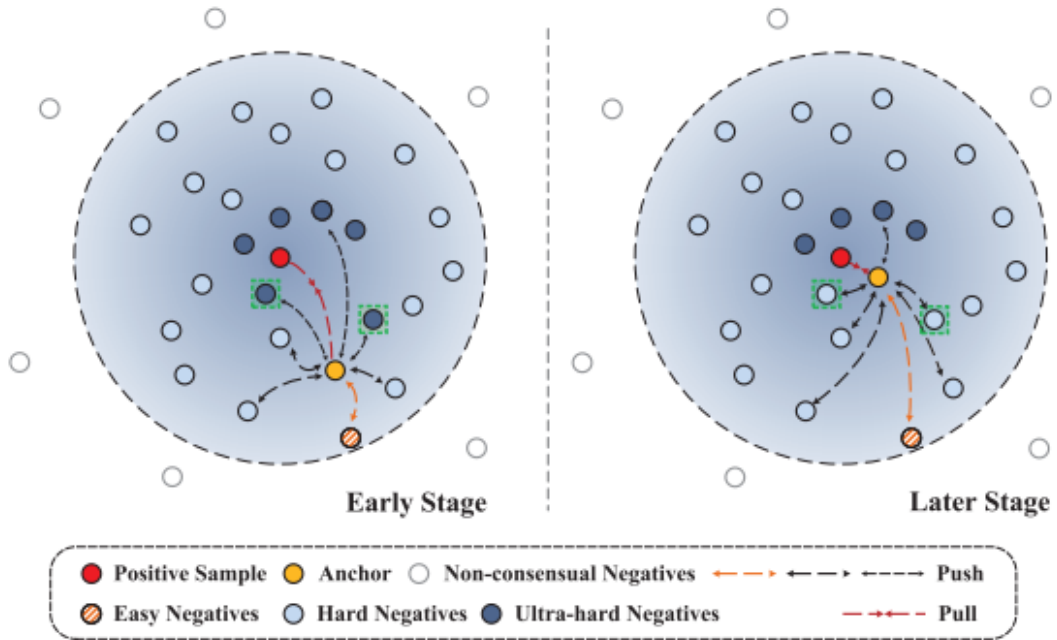


Figure 4. Illustration of curricular contrastive regularization.

图 4. 课程对比正规化说明。

基于对图 1 的分析, 提出了一种新颖的对比度正则化去雾方法, 该方法在共识空间中利用了负值, 可以从其他去雾模型中恢复结果。我们的直接目标是让锚远离质量更好的负面新闻。然而, 关键的问题有两个: 1) 如何定义不同否定的难度; 2) 在训练过程中如何根据这些否

定的难度进行排列。

为了解决这两个问题，我们将课程学习策略纳入对比正规化。我们将消极元素的难度定义为三个级别：简单、困难和超困难。为了简单的负，我们一直使用模糊输入。其他消极的难度水平是在训练过程中动态决定的。具体来说，我们在每个纪元开始之前测量网络的平均 PSNR 性能。在第  $t$  个时代，负数被定义为当 PSNR 高于网络性能时的超硬样本，反之为硬负数。为了合理地安排这些消极因素，我们会根据它们的难度水平对它们进行不同的衡量。第一，易负的权重是固定且最大的。这是因为，尽管硬的和超硬的消极可能有助于更紧凑的解决方案空间，但它们也可能导致学习歧义。为了确保合力朝向正方向，这样锚就会朝期望的方向移动，我们给简单的负方向一个足够大的权重。在实践中，我们将该权值设为非容易负  $z$  的个数。第二，None-easy 负  $S_q$  在第  $t$  epoch 的权值定义如下：

$$W_t(S_q) = \begin{cases} 1 + \gamma, & \text{avgPSNR}(f(\{I_g\}, \theta_{t-1})) \geq \text{PSNR}(S_q), \\ 1 - \gamma, & \text{otherwise,} \end{cases} \quad (2)$$

其中  $\{I_g\}$  表示含雾的输入数据集， $q = 1, 2, \dots, z$  是非简单负样本的索引，而  $\gamma$  是一个超参数。硬负样本和超硬负样本的权重分别被设定为  $1 + \gamma$  和  $1 - \gamma$ 。这意味着一个硬负样本的权重比一个超硬负样本的要大，使得硬负样本能够提供更大的作用力，并减轻潜在的学习歧义。此外，这种策略在确定困难级别的灵活性允许在训练的后期阶段将超硬负样本变为硬负样本（见图 4）。这是有道理的，因为随着锚图像质量的提高，由超硬样本引起的歧义被减少，它们的重要性应该被加强。在这种方式下，锚和超硬负样本可以被视为是在解空间中的下界，从而有效地约束解空间。然后，我们的课程对比正则化  $R^*$  被如下定义：

$$R^* = \sum_{i=1}^n \xi_i \frac{\|V_i(J) - V_i(f(I, \theta))\|_1}{\sum_{q=1}^z W_t(S_q) \|V_i(S_q) - V_i(f(I, \theta))\|_1 + z \cdot E_i}. \quad (3)$$

最后，总目标函数  $\mathcal{L}$ ，它由一个基于 L1 范数的忠诚度项和我们的对比性课程正则化组成，其表达式如下

$$\mathcal{L} = \|J - f(I, \theta)\|_1 + \lambda R^*. \quad (4)$$

### 3.4 网络架构

文中的  $C^2PNet$  采用了类似 FFA-Net 的骨干网络，原因如下：1) FFA-Net 有一个简单的结构，它串联了几个 FA 块而没有任何其他冗余模块，2) FA 块本身结构简单并且已被证明是实用的。由于提出的 PDU 主要关注于精炼空间信息，通过替换 PA 模块将其部署到每个 FA 块中。通过这种方式，特征在被输入到后续模块之前，被强制与雾化过程相一致。注意， $C^2PNet$  的所有其他网络参数都与 FFA-Net 相同，除了 PDU 外。

## 4 复现细节

### 4.1 与已有开源代码对比

文复现了作者所提出的基于 C2Pnet 网络的课程对比正则化模型，因为作者的数据集必须转换成 lmdb 格式且必须有 n1-n6 等算法的图像处理结果作为属性加入到 lmdb 文件中，但作者并没有提供 n1-n6 图像处理的具体算法逻辑，所以无法更换数据集，没做修改。但用原始数据集验证了作者所提出模型的有效性。

### 4.2 实验环境搭建

表 1. 本地实验环境

操作系统	Windows 11 家庭中文版 22H2
处理器	12th Gen Intel(R) Core(TM) i7-12700 @ 2.10 GHz
内存 RAM	16.0 GB (15.7 GB 可用)
存储器容量	1000GB
系统类型	64 位操作系统, 基于 x64 的处理器

表 2. 服务器端配置

CPU	12 X Intel(R) Xeon(R) CPU E5-2678 v3
GPU	NVIDIA Tesla P100-16GB
显存	16.0 GB
内存	48GB
硬盘	200GB

### 4.3 实验过程

整个项目使用的是常用的去雾 RESIDE 数据集，它的每个通道大气光  $A$  在  $[0.7, 1.0]$  之间，均匀地随机选择  $\beta$  在  $[0.6, 1.8]$ 。因此，它包含成对的清晰和模糊的图像，其中清晰的地面实况图像可以导致多个对，其朦胧图像是在不同的参数  $A$  和  $\beta$  下生成的。在训练集部分，使用的是 ITS 室内数据集，把它转换成了 lmdb 格式，读取的时候可直接在内存中访问，显著提高读写数据的速度。ITS 训练集包含了 13990 个合成的模糊图像，通过在不同的参数大气光  $A$  和散射系数  $\beta$  下，1 张清晰的图像生成 10 张模糊图像。其中 13000 张用于训练，990 个用于验证。

在训练过程中，通过给定的索引加载返回一对无雾和有雾的图像，还确保了图像尺寸与预定裁剪大小一致，crop 设置为 240，并通过 augData 随机进行水平翻转和旋转做增强。训练过程中定义了一个余弦衰减学习率调度函数。这个函数会根据当前步数  $t$  和总步数  $T$  调整



学习率。随着训练的进行，学习率会先减小后增大。并定义一个课程权重函数，根据图像的难易程度来调整它们在训练过程中的权重。这是课程学习策略的一部分。如果测试集是 OTS 的时候，diff list = [17.43, 18.12, 30.86, 31.98, 32.98, 33.57] 代表特定难度值，表了不同难度级别的图像。这部分计算了每个难度级别的权重，如果图像的难度大于某个阈值，它的权重会增加；如果小于阈值，权重则减小。这些权重随后被标准化，以便它们的和为 1。

对于图像的处理流程来说，输入图像首先经过预处理层，它将图像从原始的颜色空间（如 RGB）映射到一个更高维的特征空间，以便于后续的处理。经过预处理后的图像依次通过多个 Group 层。每个 Group 层包含多个 Block，这些 Block 结合卷积、激活函数、通道注意力机制（CALayer）和物理解耦单元（PDU）来处理图像。这些层的目的是逐步提取和细化图像的特征。在经过所有 Group 层之后，图像通过一个通道注意力模块，该模块进一步强调重要的特征通道。接着，图像被送入物理解耦单元（PDU），这一单元专门处理图像的物理属性，如光照和反射情况，这对去雾等任务至关重要。最后，图像通过后处理层，这通常包括一系列卷积层，它们将高维特征映射回原始的颜色空间，生成最终的处理后图像。另外，n1 到 n6 代表不同程度或类型的负样本，这些负样本可以用于增强模型的鲁棒性和适应性。它们可能被用作额外的训练输入，与原始图像一起处理，以帮助模型学习如何从不同类型和程度的退化中恢复出清晰的图像。

训练参数设置大部分采用原论文中的推荐数值，batchsize 由于机器算力原因调整为 4，学习率参数设置为 0.0001。训练的迭代次数设置为 100w 轮。block 块设置成 19，gps 设置成 3，由训练完成后 loss 值与在验测试上的表现判断，模型已正常收敛，所训练结果模型为 itstrainC2PNet319defaultclr.pk。

## 5 实验结果分析

模型评估主要由定性与定量两方面展开。定性方面主要是根据目视解译的效果来检测模型是否完成了去除云层的工作，定量方面主要根据以下三种评估指标进行精度的评定。

- **峰值信噪比 PSNR**。衡量最大值信号和背景噪音之间的差异。定义公式如下：

$$PSNR = 10 \log_{10} \left( \frac{(2^n - 1)^2}{MSE} \right) \quad (5)$$

- **SSIM（结构相似性指数）**是一种评估图像质量的方法，特别用于比较压缩或处理后图像与原始图像之间的相似性。与传统的基于像素差异的指标不同，SSIM 更加关注图像的结构信息。它基于三个比较测量：亮度、对比度和结构，从而能够更全面地评估图像质量。

SSIM 的计算公式为：

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (6)$$

1) 展示部分自己训练所得的去雾效果，使用了 ITS 数据集未去雾之前的室内 SOTS 数据集如图 5所示:




图 5. 室内未去雾之前效果

在使用了自己训练的模型后对图像进行去雾处理的结果如图 7所示:




图 6. 室内去雾后效果

由图中可知，在 ITS 数据集上训练的模型能较好的检测到雾，并且也能正确的去雾。对比结果如下表所示，由此可得，在 SOTS-indoor 测试集的表现优异，自己训练的模型与论文中可达到的结果基本无差别，PSNR 误差在 0.92 个百分点，SSIM 误差甚至到了 0.0004 个百分点。表 4 展示了模型性能比较。

	PSNR	SSIM
论文指标	42.56	0.9954
预训练模型	42.56	0.9953
自己训练模型	41.62	0.9951

表 3. 模型性能对比

2) 这里展示部分用去雾效果的对比，使用了 ITS 数据集未去雾之前的室外 SOTS 数据

集如图 7所示:




图 7. 室外未去雾之前效果

在使用了自己训练的模型后对 SOTS 室外图像进行去雾处理的结果如图 8所示:



图 8. 室外去雾后效果

由图中可知,在 ITS 室内数据集训练所的结果在 OTS 室外测试集上训练效果不佳,PSNR 百分点降低了 17.261, SSIM 百分点降低了 9.1692, 去雾效果会产生一些黑影, 甚至图片不清晰。表 4 展示了模型性能比较。

	PSNR	SSIM
论文指标	36.68	0.9900
预训练模型	34.07	0.9861
自己训练模型	16.81	0.8168

表 4. 模型性能对比

## 6 总结与展望

在本文中，提出了一种新颖的 C2PNet 用于单幅图像去雾。不使用非一致同意的负样本，而是引入一致同意的否定来构建对比样本，然后应用课程对比正则化，考虑到否定的难度，以约束更紧凑的解决空间。为了增强特征空间的解释性，我们进一步设计了一个基于物理模型的物理软件双分支单元。该单元产生的特征强制符合雾霾过程，从而促进雾霾去除。大量实验证明了该方法的有效性和通用性。

本文复现了作者所提出的相关工作，并验证了基于 C2PNet 网络的课程对比正则化对去雾的效果。从目视效果看，如果在 ITS 室内数据集上网络训练在对应的室内 SOTS 测试集上表现效果较好，基本能够完成去雾任务，同时也能较好的分离雾与其余信息。但在 SOTS 室外测试集上效果不佳，由此说明，去雾模型必须在相应类型上及其应用才能得到更好的效果。现有去雾模型的缺点的一个重要点是恢复中嵌入的去雾后先验，例如雾霾残留的分布，这可以表明一个更有挑战性的模式，很难去除。这可以在训练期间为模型提供有价值的信息。然而，由于现有的大多数方法在现实场景中表现不佳，很难收集高质量的图像，因为底片不容易（尤其是超难负样本）。这可能会限制我们模型的能力，尽管在现实世界的去雾中取得了很好的性能。未来考虑在更大规模的数据集上进行训练与验证，同时修改模型的架构，尝试不同的网络模型，对比去雾训练的效果。

## 参考文献

- [1] Bolun Cai, Xiangmin Xu, Kui Jia, Chunmei Qing, and Dacheng Tao. Dehazenet: An end-to-end system for single image haze removal. *IEEE transactions on image processing*, 25(11):5187–5198, 2016.
- [2] Wei-Ting Chen, I-Hsiang Chen, Chih-Yuan Yeh, Hao-Hsiang Yang, Jian-Jiun Ding, and Sy-Yen Kuo. Sjdl-vehicle: Semi-supervised joint defogging learning for foggy vehicle re-identification. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 347–355, 2022.
- [3] Zeyuan Chen, Yangchao Wang, Yang Yang, and Dong Liu. Psd: Principled synthetic-to-real dehazing guided by physical priors. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 7180–7189, 2021.
- [4] Jiangxin Dong and Jinshan Pan. Physics-based feature dehazing networks. In *Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXX 16*, pages 188–204. Springer, 2020.
- [5] Yong Du, Junjie Deng, Yulong Zheng, Junyu Dong, and Shengfeng He. Dsdnet: Toward single image deraining with self-paced curricular dual stimulations. *Computer Vision and Image Understanding*, 230:103657, 2023.

- [6] Yong Du, Guoqiang Han, Yinjie Tan, Chufeng Xiao, and Shengfeng He. Blind image denoising via dynamic dual learning. *IEEE Transactions on Multimedia*, 23:2139–2152, 2020.
- [7] Chun-Le Guo, Qixin Yan, Saeed Anwar, Runmin Cong, Wenqi Ren, and Chongyi Li. Image dehazing transformer with transmission-aware 3d position embedding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5812–5820, 2022.
- [8] Kaiming He, Jian Sun, and Xiaoou Tang. Single image haze removal using dark channel prior. *IEEE transactions on pattern analysis and machine intelligence*, 33(12):2341–2353, 2010.
- [9] Boyi Li, Wenqi Ren, Dengpan Fu, Dacheng Tao, Dan Feng, Wenjun Zeng, and Zhangyang Wang. Benchmarking single-image dehazing and beyond. *IEEE Transactions on Image Processing*, 28(1):492–505, 2018.
- [10] Ye Liu, Lei Zhu, Shunda Pei, Huazhu Fu, Jing Qin, Qing Zhang, Liang Wan, and Wei Feng. From synthetic to real: Image dehazing collaborating with unlabeled real data. In *Proceedings of the 29th ACM international conference on multimedia*, pages 50–58, 2021.
- [11] Xu Qin, Zhilin Wang, Yuanchao Bai, Xiaodong Xie, and Huizhu Jia. Ffa-net: Feature fusion attention network for single image dehazing. In *Proceedings of the AAAI conference on artificial intelligence*, volume 34, pages 11908–11915, 2020.
- [12] Wenqi Ren, Si Liu, Hua Zhang, Jinshan Pan, Xiaochun Cao, and Ming-Hsuan Yang. Single image dehazing via multi-scale convolutional neural networks. In *Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part II 14*, pages 154–169. Springer, 2016.
- [13] Christos Sakaridis, Dengxin Dai, Simon Hecker, and Luc Van Gool. Model adaptation with synthetic and real data for semantic dense foggy scene understanding. In *Proceedings of the european conference on computer vision (ECCV)*, pages 687–704, 2018.
- [14] Qiang Wen, Yinjie Tan, Jing Qin, Wenxi Liu, Guoqiang Han, and Shengfeng He. Single image reflection removal beyond linearity supplementary materials.
- [15] Qingsong Zhu, Jiaming Mai, and Ling Shao. A fast single image haze removal algorithm using color attenuation prior. *IEEE transactions on image processing*, 24(11):3522–3533, 2015.